

► Подбор гиперпараметров модели

Солодова София Михайловна М8О-309Б-23
Cardiovascular Disease Dataset

► Постановка задачи



ЗАДАЧА

Бинарная классификация –
прогноз наличия сердечно-
сосудистых заболеваний



ОБЪЕМ ДАННЫХ

70 000 наблюдений
12 признаков



ЦЕЛЬ РАБОТЫ

- Сравнить методы подбора гиперпараметров
- Проанализировать эффективность AutoML (ТРОТ)
- Исследовать интерпретируемость моделей

► ПОДГОТОВКА ДАННЫХ

01

Удаление идентификатора (id)

02

Разделение на train/test(80/20)

03

Создание пайплайна с CatBoostClassifier

► Проблема

- Несбалансированные классы
- Разнородные признаки

► Особенности

- CatBoost сам обрабатывает категориальные признаки (one-hot не требуется)
- Pipeline для последующего использования в Grid/Random search

► Grid Search



Принцип работы

Полный перебор всех комбинаций параметров
Точный, но вычислительно дорогой



Преимущества

Гарантированно находит оптимальную комбинацию в заданном пространстве
Прост в реализации



Математическая основа

```
for params in parameter_grid:  
    model = Model(**params)  
    score = cross_val_score(model, X, y)  
    update_best_if_needed(score, params)
```



Недостатки

Экспоненциальный рост времени выполнения
Неэффективен для больших пространств параметров

► Random Search



Принцип работы

Случайная выборка из пространства параметров
Вероятностный подход



Математическая основа

```
for i in range(n_iter):  
    random_params = sample(parameter_distribution)  
    score = evaluate_model(random_params)
```



Преимущества

Быстрее Grid Search
Эффективен для high-dimensional пространств
Хорош для первоначального исследования



Недостатки

Не гарантирует нахождение оптимума
Может пропускать важные области

► Байесовская оптимизация (Optuna)



Принцип работы

Строит вероятностную модель целевой функции
Балансирует exploration/exploitation



Математическая основа

Использует surrogate model (часто Gaussian Process)
Acquisition function (EI, UCB) для выбора следующей точки



Преимущества

Умный поиск - учится на предыдущих итерациях
Эффективен для дорогих функций
Хорош для сложных пространств



Недостатки

Сложность реализации
Зависимость от выбора surrogate model

► Genetic Programming (ГПОТ)



Принцип работы

Эволюционные алгоритмы для оптимизации пайплайнов
"Скрещивание" и "мутация" конвейеров



Основные операции

Selection - отбор лучших пайплайнов

Crossover - комбинация частей пайплайнов

Mutation - случайные изменения



Преимущества

Автоматический подбор не только параметров, но и алгоритмов
Находит неочевидные решения
Генерирует готовый Python код



Недостатки

Долгое время выполнения для сложных задач
Требует значительных ресурсов

► SHAP (SHapley Additive exPlanations)



Принцип работы

Теория игр Шепли для распределения "вклада" между признаками
Справедливое распределение влияния на prediction



Математическая основа

$$\text{SHAP_value}(i) = \sum [f(S \cup \{i\}) - f(S)] * |S|!(M-|S|-1)!/M!$$



Преимущества

Теоретически обоснованный метод
Локальная и глобальная
интерпретируемость
Работает с любыми моделями



Типы объяснений

Force plot - вклад в конкретное предсказание
Summary plot - глобальная важность признаков
Dependence plot - зависимость предсказания от признака

▶ Сравнение методов

Метод	Точность	Время	Лучшая модель	Ключевые параметры
GridSearch	0,7770	~20min	CatBoost	Depth=6 lr=0.05
RandomSearch	0,7772	~15min	CatBoost	Subsample=0.9
Optuna	0,7764	~10min	CatBoost	Iterations=660
Trot	0,7752	~1h	MLPClassifier + preprocessing	Auto-pipeline

► Анализ ТРОТ

01 **MaxAbsScaler** - масштабирование

02 **RFE, ExtrasTreesClassifier** – отбор признаков

03 **FeatureUnion** – комбинация преобразований

04 **XGBClassifier** – финальная модель

► Особенности

Автоматический подбор preprocessing steps

Комбинация нескольких алгоритмов

Готовый код для использования

► Интерпретация моделей (LIME)




Пример анализа

- Наблюдение #7: модель уверенно предсказывает "Cardio" (85%)
 - Ключевые факторы: холестерин, артериальное давление, возраст пациента




 Визуализация

- Веса признаков для конкретного предсказания
 - Факторы "за" и "против" класса




► Практическое применение SHAP




Локальные объяснения:

- Почему конкретный пациент отнесен к классу "Cardio"
- Вклад каждого признака в предсказание



Summary plot:

- Важность признаков
- Распределение влияния признаков на модель



Dependence plots:

- Как изменение признака влияет на предсказание
- Взаимодействия между признаками

► Выводы

01

GridSearch – наиболее стабильный и интерпретируемый результат

02

RandomSearch – лучшая точность

03

Optuna – лучший баланс точности и времени

04

ТРОТ – в данной задаче показал худшие результаты

05

Интерпретация критически важна для медицинских приложений

